

NIPT 检测时点选择与胎儿染色体异常判定

摘要

本文针对 NIPT 中男胎 Y 染色体浓度达标时点选择与女胎染色体异常判定问题，建立纵向浓度模型、区间删失离散风险模型、带约束的 BMI 有序分组模型和校准 Logistic 分类模型。数据包含男胎 1082 条检测记录、267 名孕妇，以及女胎 605 条检测记录、147 名孕妇。同一孕妇可能接受多次检测，因此所有验证均以孕妇代码为分组单位，防止同一人的记录同时进入训练集和验证集。

对于男胎，先以随机截距吸收孕妇内相关性，并以孕周、BMI 的样条项和交互项描述 Y 染色体浓度。该模型的五折验证 RMSE 为 0.03307，但折外 R^2 仅为 0.0254，说明可观测变量对单次浓度波动的解释力有限。进一步把首次达到 4% 看作区间删失事件，建立离散时间风险模型。在每组至少 35 人的约束下，对连续 BMI 分区和检测时点联合搜索，得到切点 29.14 和 34.50，三组建议分别在第 14、15、16 周检测。风险权重及测量阈值敏感性分析表明，BMI 切点稳定，而推荐时点会随漏检代价上升而推迟。

对于女胎，以 AB 是否为空作为主二分类标签，以 T13、T18、T21 为次级多标签，采用嵌套的按孕妇分组交叉验证，在内层选择正则强度、校准概率并确定阈值。最终选择较简单的路线 A，其主任务平衡准确率为 0.712、灵敏度为 0.582、特异度为 0.842、PR-AUC 为 0.376。该结果适合作为风险筛查模型，不可替代临床诊断；尤其 T21 阳性样本过少，结论不稳定。

关键词：NIPT；纵向数据；区间删失；离散时间风险；有序分组；概率校准

1 问题重述

NIPT 通过母体外周血中的胎儿游离 DNA 信息判断染色体异常。既有研究表明，孕周、孕妇体重或 BMI 会影响胎儿游离 DNA 比例及无结果风险[1]。男胎样本中 Y 染色体浓度达到 4% 后，检测结果通常更可靠；但较晚检测又会增加异常发现过迟的风险。因此需要同时估计 Y 浓度与孕周、BMI 等因素的关系，按 BMI 划分合理人群，并选择兼顾检测失败和延迟发现的检测时点。女胎不含 Y 染色体，需要利用常染色体与 X 染色体 Z 值、测序质量和孕妇信息判定异常。

本文解决四个问题：

1. 建立男胎 Y 染色体浓度与孕周、BMI 的关系模型并评价其统计表现；
2. 仅依据 BMI 对男胎孕妇分组，给出各组最佳检测时点；
3. 加入年龄、身高、体重、妊娠方式与测序质量，并考虑测量误差和达标概率；
4. 对女胎建立 AB 总体异常判定，并给出 T13、T18、T21 次级结果。

2 数据处理与基本假设

2.1 数据处理

将“检测孕周”的 w+d 字符串转换为连续周数

$$t=w+(d)/(7). \quad (1)$$

以孕妇代码识别个体，以检测日期和抽血次数区分纵向记录。数值缺失值在训练折内以该变量均值填补，随后使用训练折均值和标准差进行标准化。女胎 Y 染色体相关空列不进入模型；出生后才可知的“胎儿是否健康”字段不进入预测，避免未来信息泄漏。

女胎 AB 列为空记为总体正常，非空记为总体异常 ANY=1；字符串中出现 T13、T18、T21 时，分别生成对应标签。所有交叉验证、超参数选择和阈值选择均按孕妇代码分组。

2.2 基本假设

1. 在给定已观测孕妇与测序变量后，随访终止近似为非信息删失。
2. Y 浓度的总体变化随孕周和 BMI 平滑变化，但允许孕妇间存在随机水平差异。
3. 第一次未达标与第一次达标检测之间发生首次达标，可用区间删失表示。

4. BMI 分组必须连续、有序且具有足够样本量，避免只为降低样本内损失而产生极小组。
5. 附件样本代表本题数据人群；由于样本明显偏向较高 BMI，结论不直接外推至未覆盖人群。

3 问题一：Y 染色体浓度关系模型

3.1 基线模型

设第 i 名孕妇第 j 次检测的 Y 浓度为 Y_{ij} ，孕周为 t_{ij} ，BMI 为 b_{ij} 。基线模型为

$$Y_{ij} = \beta_0 + \beta_1 t_{ij} + \beta_2 b_{ij} + \beta_3 t_{ij} b_{ij} + u_i + \varepsilon_{ij}, \quad (2)$$

其中 u_i 为孕妇随机截距， ε_{ij} 为记录层误差。计算中采用带惩罚的交替最小二乘估计随机截距，防止多次检测较多的孕妇对模型产生过大影响。

3.2 非线性主模型

为刻画孕周增长曲线及 BMI 的非线性影响，路线 B 使用广义加性模型的平滑函数思想[2]，以截断三次样条构造非线性基：

$$Y_{ij} = \beta_0 + f(t_{ij}) + g(b_{ij}) + \gamma t_{ij} b_{ij} + u_i + \varepsilon_{ij}. \quad (3)$$

样条结点由训练数据分位数确定，固定效应与随机截距均加入 L2 惩罚。五折验证严格按孕妇划分。路线 B 的 RMSE、MAE 和 R^2 分别为 0.03307、0.02695 和 0.0254；路线 A 的 RMSE 为 0.03336。B 的误差略小，但其 RMSE 95% Bootstrap 区间为 [0.03064, 0.03543]，与 A 的区间重叠。

为直接检验关系显著性，进一步在路线 A 中按孕妇进行 120 次有放回 Bootstrap。BMI 的标准化系数为 -0.00978，95% 区间为 [-0.01753, -0.00191]，双侧符号检验 $p=0.0167$ ，表明在该模型和样本范围内 BMI 与 Y 浓度呈显著负向关系。孕周主效应和孕周与 BMI 交互项的区间均跨 0，分别得到 $p=0.8667$ 和 $p=0.3000$ ，未发现显著的独立线性效应。

因此，BMI 的负向关联具有统计证据，但孕周效应更适合由非线性概率模型描述。即便如此，路线 B 的总体折外解释力仍较低，不能解释大部分单次测量波动。后续时点决策不直接把浓度点预测当作确定值，而使用达标概率并保留不确定性。




图1 不同BMI水平下Y染色体浓度与孕周的观测及路线B固定效应拟合

4 问题二与问题三：BMI 分组和检测时点

4.1 首次达标的区间删失模型

定义

$$T_i = \inf t: Y_i(t) \geq 0.04. \quad (4)$$

若孕妇先在 L_i 周末达标、后在 R_i 周达标，则仅知道 $T_i \in (L_i, R_i]$ ；首次检测即达标视为左删失，随访结束仍未达标视为右删失。该表述与区间删失分布估计的经典框架一致[3]。数据中三类数量分别为 43、217 和 7。

在半周网格上定义离散风险

$$h_i(t) = P(T_i = t \mid T_i \geq t, x_i(t)) = \text{logit}^{-1}(x_i(t)^T \theta), \quad (5)$$

以及生存概率和累计达标概率

$$S_i(t) = \prod_{s \leq t} [1 - h_i(s)], \quad F_i(t) = 1 - S_i(t). \quad (6)$$

区间删失、左删失和右删失的似然贡献依次为

$$S_i(L_i) - S_i(R_i), \quad 1 - S_i(R_i), \quad S_i(L_i). \quad (7)$$

协变量包括孕周样条、BMI、年龄、身高、体重、IVF 指示、GC 含量、比对比例和过滤比例等。优化 3000 步后，最后两个记录点的惩罚对数似然差为 2.38×10^{-7} ，表明数值过程已稳定。

4.2 风险函数与分组约束

对 BMI 组 g 在孕周 t 的检测风险定义为

$$R_g(t)=c_f(1)/(n_g)\sum_{i\in g}[1-F_i(t)]+c_dD(t), \quad (8)$$

其中 c_f 表示过早检测导致未达标的代价, c_d 表示延迟代价, 且

$$D(t)=(\max(t-12, 0))/(15). \quad (9)$$

主情景取 $c_f=3, c_d=1$ 。从 BMI 分位点生成候选切点, 枚举 3 至 5 个连续有序组, 并要求每组至少 35 名孕妇。对每个可行分区, 在 10 至 25 周的半周网格上求组内最小风险。共有 46 个分区满足约束, 因此所得解是预先规定候选集合内的最优解, 而非连续空间的全局最优证明。

4.3 分组结果

BMI 区间	样本量	推荐孕周	预测达标概率
<29.14	40	14.0	0.935
[29.14, 34.50)	187	15.0	0.911
≥ 34.50	40	16.0	0.844

主方案风险为 0.5156, 低于统一第 12 周检测的 0.7229。固定临床 BMI 分组的样本内风险虽为 0.4841, 但其首尾组只有 5 人和 4 人, 违反主模型的最小样本约束, 估计不稳定, 因此不采用。

4.4 多因素与误差敏感性

当失败代价 c_f 分别取 2、3、5 时, 两个 BMI 切点保持不变, 三组推荐时点依次为 [13.5, 14, 15]、[14, 15, 16] 和 [15, 16, 18] 周。这说明切点对风险偏好较稳定, 但检测时点对漏检代价敏感: 越重视一次检测成功率, 建议越晚检测。

将达标阈值从 4% 改为 3.8% 与 4.2% 时, 切点仍保持不变; 推荐时点分别为 [13.5, 14.5, 15.5] 与 [15, 15.5, 16.5] 周。若孕周存在系统误差, 建议时点相应平移约 0.5 周。因此实际应用时应结合医院的测量误差和风险偏好, 而不把单一周数视为绝对界限。

5 问题四: 女胎异常判定

5.1 模型与验证设计

以 ANY 为任务, 并分别预测 T13、T18、T21。输入包括四个 Z 值、X 染色体浓度、总体及各染色体 GC 含量、原始与唯一比对读段数、比对和重复比例、过滤比例、BMI、年龄、身高、体重、孕周、孕产史和 IVF 指示。

对每个标签建立带类别权重的 L2 Logistic 模型：

$$P(Y_k=1 \mid x) = \text{logit}^{-1}(\alpha_{(k0)} + x^T \alpha_k). \quad (10)$$

使用五折外层分组验证。每个外层训练集中再进行三折分组验证，从 0.1, 1, 10 选择 L2 强度；用内层折外预测拟合一维概率校准，并仅在内层数据上选择使平衡准确率最大的阈值。外层验证数据不参与调参、校准或阈值选择。

5.2 结果

任务	平衡准确率	灵敏度	特异度	PR-AUC	Brier
ANY	0.712	0.582	0.842	0.376	0.085
T13	0.632	0.348	0.916	0.162	0.035
T18	0.722	0.630	0.814	0.333	0.061
T21	0.537	0.077	0.997	0.101	0.021

ANY 阳性率为 0.111，其 PR-AUC 高于按流行率随机排序的基准。模型更擅长排除总体正常样本，灵敏度仍只有 0.582，因此适合作为辅助筛查或复核排序工具，不适合单独排除异常。T18 的次级结果相对较好；T21 只有 13 条阳性记录，虽然特异度高，但灵敏度仅为 0.077，不能作稳定结论。

路线 B 加入绝对 Z 值、平方项和交互项后，ANY 平衡准确率反而降至 0.663，PR-AUC 降至 0.326。复杂模型没有在折外数据上获益，因此最终选择路线 A，体现“小样本下优先采用可校准、可解释模型”的原则。

由于类别不平衡，本文采用 PR-AUC 而非仅报告普通准确率；PR 曲线在偏斜二分类数据上更能反映阳性类别的识别质量[4]。概率经附加 Sigmoid 映射校准[5]，并使用 Brier 分数评价概率误差[6]。




图2 BMI分组、风险敏感性与女胎异常判定结果汇总

6 模型评价

6.1 优点

1. 所有数据拆分均以孕妇为单位，避免纵向记录泄漏。
2. 达标时间采用区间删失似然，没有删除从未达标或首次即达标的孕妇。
3. BMI 分组同时满足顺序、连续和最小样本量约束，推荐时点与风险函数直接对应。
4. 参数、随机种子、运行日志、验证证据和最终指标均已固化，可复现并可审计。
5. Q4 使用嵌套验证与概率校准，避免在外层验证集上选择阈值。

6.2 局限

1. 男胎浓度模型折外 R^2 较低，未观测生理差异和实验误差仍占主要部分。

2. BMI 分布偏高，低 BMI 与极高 BMI 样本不足，切点不应直接推广到其他人群。
3. 风险函数中的失败代价与延迟代价缺乏统一临床标定，本文用敏感性分析代替唯一价值判断。
4. 半周离散网格限制了时点精度；更密网格需要更多观测支持。
5. 女胎异常标签不平衡，尤其 T21 样本过少；模型只能辅助筛查，必须结合临床标准与进一步检查。

7 结论

本文把男胎 Y 浓度的纵向关系、首次达标的删失结构和 BMI 分组决策统一在概率风险框架中。对附件人群，建议按 BMI 29.14 和 34.50 分为三组，并分别在第 14、15、16 周检测。该方案满足每组最少 35 人的稳定性约束，并在预设风险函数下优于统一第 12 周检测。风险偏好或测量阈值变化主要影响推荐时点，对 BMI 切点影响较小。

女胎异常判定采用校准的正则化 Logistic 模型。总体异常识别获得中等区分能力，但仍存在漏检，不能替代诊断；多标签结果中 T21 的证据尤其不足。实际应用应保留人工复核和后续临床检查，并在获得更大规模、更多正常 BMI 和更多异常病例的数据后重新训练与外部验证。

参考文献

- [1] Kinnings S L, Geis J A, Almasri E, et al. Factors affecting levels of circulating cell-free fetal DNA in maternal plasma and their implications for noninvasive prenatal testing[J]. *Prenatal Diagnosis*, 2015, 35(8): 816–822. DOI: 10.1002/pd.4625.
- [2] Hastie T, Tibshirani R. Generalized additive models[J]. *Statistical Science*, 1986, 1(3): 297–310. DOI: 10.1214/ss/1177013604.
- [3] Turnbull B W. The empirical distribution function with arbitrarily grouped, censored and truncated data[J]. *Journal of the Royal Statistical Society: Series B*, 1976, 38(3): 290–295. DOI: 10.1111/j.2517-6161.1976.tb01597.x.
- [4] Davis J, Goadrich M. The relationship between precision-recall and ROC curves[C]//*Proceedings of the 23rd International Conference on Machine Learning*. 2006: 233–240. DOI: 10.1145/1143844.1143874.
- [5] Platt J C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods[M]//*Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999: 61–74.

- [6] Brier G W. Verification of forecasts expressed in terms of probability[J]. Monthly Weather Review, 1950, 78(1): 1-3. DOI: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

附录：支撑材料文件列表

1. tools/c_problem_experiment.py: 数据处理、路线A/B建模、分组优化、嵌套验证与敏感性分析。
2. workspace/experiments/experiment_plan.json: 正式批量实验配置。
3. workspace/experiments/FROZEN_RESULTS.json: 人工接受结果及SHA256清单。
4. workspace/claims/claim_ledger.json: 结论与冻结实验的对应关系。
5. workspace/figures/: 两幅论文插图及其可复现输出。